

Programmazione consapevole (semplice è bello)

Andrea Salmaso

17 giugno 2018

Indice

1	Introduzione	7
1.1	Struttura di un computer	7
1.2	Come scrivere ed eseguire un programma	7
1.3	Notazione	7
2	Tipi predefiniti e variabili	9
2.1	Tipi predefiniti	9
2.2	Variabili e dichiarazioni	11
2.3	Espressioni e conversioni	12
2.4	A cosa servono i tipi	13
3	Istruzioni di base	15
3.1	Input/Otput	15
3.1.1	I file	16
3.1.2	Collegamento tra programma e file	17
3.1.3	Operazioni di i/o	18
3.2	Assegnazione	20
3.3	Condizionale	21
3.4	Cicli while	21
3.5	Esempi	22
3.6	Sulla visibilità delle variabili	26
4	La correttezza dei programmi	31
4.1	Regola di prova del <i>while</i>	31
4.2	Altri esempi di prove di correttezza	31
4.2.1	Esempio di gestione delle eccezioni	31
5	Puntatori, array ed aritmetica dei puntatori	33
5.1	Puntatori e riferimenti	33
5.2	Array e for	33
5.3	Il tipo degli array	33
5.4	L'aritmetica dei puntatori	33
5.5	Stringhe alla C e array di caratteri	33
6	?	35
7	Funzioni	37
7.1	Funzioni	37
7.2	Passaggio dei parametri	37
7.3	Funzioni ed arrays	37

7.4	Variabili globali	37
7.5	Funzioni e valori restituiti	37
7.6	Esercizi commentati sulle funzioni	37
7.7	Esercizi proposti	37
8	Gestione dinamica dei dati e liste	39
8.1	Gestione dinamica dei dati	39

Prefazione Lo scopo del libro è duplice. In primo luogo si propone di insegnare un linguaggio di programmazione semplice e popolare e in secondo luogo, intende sviluppare nei lettori la capacità di usare la programmazione in modo scientifico per risolvere problemi. Questo significa, in primo luogo, definire in modo preciso problemi da affrontare e successivamente spiegare, in modo altrettanto chiaro, perché i programmi proposti per risolverli effettivamente lo fanno. Il linguaggio di programmazione è C++ senza la parte orientata agli oggetti. In pratica si tratta del linguaggio C con alcune caratteristiche aggiuntive che lo rendono più facile da usare rispetto al semplice C.

Il libro non assume alcuna conoscenza preliminare di Informatica ed è quindi pensato per un corso iniziale di programmazione, sia in una scuola superiore, sia nella Laurea (triennale) in Informatica o in Ingegneria Informatica. Il testo abbonda di esercizi, sia risolti che aperti. Ogni programma presentato nel libro è accompagnato da una dimostrazione di correttezza intuitiva, ma anche ragionevolmente precisa. La programmazione ricorsiva viene trattata diffusamente e la correttezza dei programmi ricorsivi viene dimostrata usando l'induzione.

Capitolo 1

Introduzione

1.1 Struttura di un computer

1.2 Come scrivere ed eseguire un programma

1.3 Notazione

Capitolo 2

Tipi predefiniti e variabili

Come (quasi) tutti i linguaggi di programmazione, anche il C++ *offre* dei tipi belli e pronti per l'uso. Si chiamano tipi **predefiniti** e naturalmente servono a rappresentare valori praticamente onnipresenti nei problemi che si affrontano con la programmazione e cioè gli interi, i reali, i caratteri, e i booleani. Cercheremo di presentarli in modo particolarmente compatto e mettendo in luce immediatamente i problemi che nascono dalla coesistenza nei nostri programmi di valori di tipo diverso e che di conseguenza sono rappresentati nella RAM in modo diverso. In particolare, discuteremo di conversioni tra valori di tipi diversi e accenneremo anche al concetto di *sovraccaricamento o overloading* degli operatori. Introduciamo anche le **variabili**, che in C++ devono sempre avere un tipo, ed inizieremo ad illustrare la nozione di **visibilità** o **scope** delle variabili stesse. Chiuderemo il capitolo illustrando l'importanza che i tipi hanno per l'individuazione degli errori che sono spesso presenti nei programmi che vengono scritti.

2.1 Tipi predefiniti

I tipi predefiniti del C++ sono i seguenti: il tipo intero, due tipi per i reali, un tipo carattere, il tipo booleano ed il tipo `void`. La Tabella 2.1 contiene alcune utili informazioni su questi tipi. La colonna `BYTE` di questa tabella specifica quanti byte vengono usati dal compilatore GNU C++4.1 per rappresentare nella RAM i valori dei diversi tipi. Questa quantità è importante perché essa fissa l'insieme dei valori supportati per ciascun tipo. È importante chiarire subito che, benché, per esempio, l'insieme degli interi sia infinito in matematica, gli interi che un computer supporta saranno sempre in numero finito, visto che ogni computer ha una memoria finita.

- Per il tipo intero, l'intervallo dei valori rappresentabili con 4 byte (dal compilatore GNU 4.1) è, -2^{31} , ..., $2^{31} - 1$. Le tipiche operazioni applicabili ai valori interi sono quelle aritmetiche (`+` `-` `/` `*` e `%` che rappresenta il modulo). Oltre a queste sono applicabili ai valori interi anche le operazioni di confronto, cioè il test di uguaglianza `==`, il test di disuguaglianza `!=`, il test di maggiore `>`, il test di maggiore o uguale `>=`, eccetera. L'ambiente C++ fornisce 2 costanti `INT_MAX` e `INT_MIN` che hanno come valore, rispettivamente, il massimo ed il minimo intero rappresentabile. Useremo spesso queste costanti per inizializzare variabili intere con un valore che sia sicuramente il più grande o il più piccolo possibile. Visto che gli interi rappresentati nel computer sono finiti, è naturale chiedersi cosa succede se sommando o moltiplicando 2 interi

si esce dall'intervallo dei valori rappresentabili. In questo caso diremo che si è verificato un errore di **overflow** ed il risultato dell'operazione è privo di senso. Purtroppo l'overflow non viene, in generale, segnalato automaticamente dal computer.

- Per i reali il C++ offre 2 tipi: `double` e `float`. Il tipo `double` che occupa 8 byte offre maggiore precisione del `float` per cui si usano solo 4 byte. Una costante reale come 12.3 viene considerata dal compilatore di tipo `double`. È necessario aggiungere `f` alla fine per renderla `float`: 12.3f. La scrittura 2.3⁴ indica il numero `double` 2.3*10⁴.
- Le operazioni aritmetiche e quelle di confronto si possono applicare sia a valori `int`, che `float`, che `double`. Chiariamo immediatamente che non si tratta delle stesse operazioni, ma solo di simboli uguali per indicare operazioni diverse. La diversità è causata dalla diversa rappresentazione interna degli interi (complemento a 2) rispetto a quella dei reali (floating point con 4 o 8 byte). Questo fenomeno di indicare con lo stesso simbolo operazioni simili concettualmente, ma che sono diverse a causa del tipo degli operandi, si chiama **sovraccaricamento** o **overloading**. Vedremo nel seguito del capitolo come il compilatore decide qual'è l'operazione che deve venire effettivamente usata a fronte di un'operazione sovraccaricata nel programma che sta traducendo.
- L'insieme di valori del tipo `char` è costituito da 256 caratteri. Il compilatore C++ 4.1 della GNU usa un byte per rappresentare questi 256 valori ed infatti con otto bit si rappresentano 256 valori diversi che visti come interi in complemento a 2 sono gli interi da -128 a 127. Quindi ogni carattere è rappresentato nella RAM da uno di questi interi. I caratteri con codifica da 0 a 127 sono i caratteri ASCII e sono i caratteri alfabetici (minuscoli e maiuscoli), i numeri, i segni di punteggiatura, le parentesi e diversi caratteri che servono a controllare il cursore come il carattere di tabulazione e quello di invio. I caratteri con codifica negativa dipendono invece dal sistema operativo che si utilizza. In generale tra questi sono presenti molti caratteri accentati, il segno di insieme vuoto ed altri caratteri utili. L'insieme dei 256 caratteri viene chiamato **extended ASCII**. In www.cplusplus.com si possono trovare informazioni più precise.

Visto che la rappresentazione interna dei caratteri è fatta attraverso interi (sebbene di 1 solo byte), ai caratteri si possono applicare le operazioni aritmetiche. Naturalmente, in questo modo è molto facile ottenere risultati che non rappresentano più caratteri, cioè che sono fuori dall'intervallo -128... 127. Come per gli errori di overflow è il programmatore che deve fare attenzione a questi possibili errori.

I valori di tipo carattere si rappresentano nei programmi tra apici, come per esempio in `'v'`, `'?'` e `'!'`, cf. la Tabella 2.1. Ci sono caratteri che non sono visibili sullo schermo, ma hanno la funzione di spostare il cursore, per esempio, il carattere `'\n'` serve per spostare il cursore all'inizio della prossima riga del video, mentre `'\t'` muove il cursore al prossimo punto di tabulazione. Con la crescente importanza di paesi che adottano alfabeti diversi dal nostro, sono nati tipi in grado di rappresentare insiemi di caratteri più ampi di 256. A questo scopo il C++ prevede il tipo `wchar_t` i cui valori occupano 2 o 4 byte.

- Il tipo booleano, denotato `bool`, consiste solamente di 2 valori, `true` e `false`. Ai valori di tipo `bool` si applicano gli operatori booleani che sono la congiunzione (AND), rappresentata con `&&`, la disgiunzione (OR), rappresentata con `||` e la negazione (NOT), rappresentata con `!`. I valori booleani sono rappresentati internamente al computer con gli interi 0 (`false`) e 1 (`true`). Il fatto che i valori del tipo `bool` siano rappresentati con interi è un'eredità del C. Visto che il C++ è compatibile col C, la stessa convenzione si applica anche al C++. Come per i caratteri, il fatto che i valori booleani siano rappresentati internamente con interi, permette di applicare ai valori booleani tutte le operazioni applicabili agli interi. Per esempio, `true - true == false` è un'espressione corretta del C++ ed ha valore `true` (con rappresentazione interna 1). Visto che i valori booleani sono in realtà interi, anche la seguente espressione, `2 && 0 || -4`, è un'espressione valida in C++ ed ha valore `true`.
- Il tipo `void` non ha valori né operazioni. Esso viene usato proprio per indicare la mancanza di valori. Vedremo il suo uso nelle funzioni che non restituiscono alcun risultato, cf. Sezione 7.3.

In generale, per sapere quanti byte occupano i valori di un qualsiasi tipo `T` possiamo utilizzare la funzione di libreria `sizeof`. L'istruzione, `cout << sizeof(T);` stampa sul video il numero di byte usati per un qualsiasi valore del tipo `T`. Oltre ai tipi predefiniti elencati nella Tabella 2.1, il C++ permette anche i tipi `short int`, `long int` e `long double`. Il significato dei qualificatori `short` e `long` è ovvio, ma in molte realizzazioni i valori di questi tipi occupano lo stesso numero di byte del tipo base a cui il qualificatore è applicato. Per esserne certi si può usare la funzione `sizeof()` descritta prima.

Un altro tipo di valore, usato molto frequentemente nei programmi, è la stringa (di caratteri). Un tale valore è usato nell'Esempio 1.1 che scrive sul video la stringa, `"inserire 2 interi"`. Queste stringhe si chiamano **stringhe alla C**, per contrasto rispetto a quelle **alla C++** che sono realizzate dal tipo contenitore `string` di cui parleremo nella Sezione 9.6. Le stringhe alla C sono dei valori costanti formati da sequenze di caratteri racchiuse tra doppi apici. Esse possono contenere qualunque carattere, anche quelli di controllo. Per esempio, se nell'Esempio 1.1 sostituissimo nella seconda riga del ma in la seguente stringa: `"inserire 2 interi \n"` a quella originale, potremmo osservare che l'output prodotto dal nuovo programma cambierebbe rispetto a quello del programma originale. Le stringhe alla C sono menzionate anche nella Sezione 5.1.

2.2 Variabili e dichiarazioni

Come tutti i linguaggi di programmazione, il C++ permette di usare dei nomi per rappresentare i dati che i programmi manipolano. Questi nomi si chiamano **variabili**(o anche identificatori). Le variabili devono iniziare sempre con un carattere alfabetico (minuscolo o maiuscolo) oppure con il carattere di sottolineatura `_` (underscore) ed i caratteri successivi possono essere o alfabetici o numerici oppure il carattere `_`. La massima lunghezza delle variabili non è fissata, ma nomi troppo lunghi possono venire abbreviati in fase di compilazione e comunque rischiano di appesantire la programmazione. Il C++ distingue i caratteri minuscoli da quelli

maiuscoli. Quindi `pippo` è una variabile diversa da `Pippo` ed entrambe sono diverse da `PIPP0`.

Le variabili vengono introdotte nei programmi C++ attraverso le operazioni di **dichiarazione** che specificano il tipo delle variabili dichiarate. Per esempio, la dichiarazione `int x, pippo;` specifica che `x` e `pippo` sono variabili di tipo `int` (o semplicemente sono variabili intere). In generale, se il programma è corretto, una tale dichiarazione garantisce che i valori che, durante l'esecuzione del programma, verranno associati alle due variabili `x` e `pippo` saranno di tipo `int`. Al momento della dichiarazione di una variabile, è anche possibile (non necessario) assegnare un valore alla variabile stessa, come per esempio in: `int x=0, pippo= -1;`. In questo caso parliamo di **inizializzazione** delle variabili. Una variabile dichiarata, ma non inizializzata, è **indefinita**. Esempi di dichiarazioni di variabili di tipo `char` sono: `char y1, z;` e `char y1=' a' , z;` in cui `y1` viene inizializzata al carattere `'a'`. I nomi delle variabili devono in ogni caso essere diversi dalle parole chiave (keyword) del C++ come, per esempio, `int` e `char` e altre che saranno introdotte nel seguito.

A volte nei programmi c'è l'esigenza di usare dei valori **costanti**, per esempio costanti numeriche, stringhe particolari, eccetera. Piuttosto che usare direttamente i valori costanti nel testo del programma conviene dichiarare nomi costanti a cui assegnare questi valori e poi usare i nomi nel testo del programma dovunque servano i valori. Le dichiarazioni di costante hanno la seguente forma: `const double pi=3.14;` oppure `const char inizio='a', fine='z';`. Quindi si tratta semplicemente di premettere la parola chiave `const` ad una normale dichiarazione. Importante notare che nel caso delle costanti l'inizializzazione è sempre richiesta al momento della dichiarazione. Il valore assegnato (ovviamente) non potrà venire modificato nel programma (pena un messaggio d'errore del compilatore). Usare dichiarazioni di costanti, rispetto ad usare direttamente i valori costanti nel testo del programma, fa guadagnare in leggibilità, in robustezza ed in facilità di modifica dei programmi. Il guadagno in leggibilità è ovvio se i nomi costanti sono scelti con intelligenza. La robustezza deriva dal fatto che accidentali modifiche di un valore che dovrebbe essere costante vengono segnalate. Per la modificabilità, è ovvio che, in caso un valore costante sia da cambiare, è certamente più semplice e sicuro modificare la corrispondente dichiarazione di costante piuttosto che modificare tutte le occorrenze del valore nel testo del programma.

2.3 Espressioni e conversioni

Un'espressione è composta nel caso più semplice da costanti, per esempio, `2*(5+24)`, il cui valore è 58. Espressioni possono contenere variabili, per esempio, `x*(pippo+24)`, il valore di questa espressione lo si calcola sostituendo ad ogni variabile il suo R-valore. Supponiamo che `x` abbia R-valore 5 e `pippo` abbia R-valore 2, in questo caso l'espressione ha valore 130. Sottolineiamo un fatto semplice, ma importante: le espressioni nei programmi vengono sempre valutate e questo procedimento (se ha successo) produce il **valore** dell'espressione. E' possibile che la valutazione di un'espressione non abbia successo? La risposta è affermativa e il fallimento della valutazione può avvenire per vari motivi. La ragione più semplice è che l'espressione richieda di eseguire operazioni indefinite come la divisione per 0. Questo errore produce generalmente una terminazione anormale del programma in esecuzione. Un altro possibile motivo che può impedire la valutazione di un'espres-

sione è che l'espressione contenga operandi ed operatori di tipi incompatibili. Una tale espressione è `"pippo" * 13` in cui si chiede di moltiplicare una stringa alla C (il cui tipo non conosciamo ancora) con un intero. Questa espressione ovviamente non ha senso e questo fatto ci verrà segnalato dal compilatore. Quindi un programma che contiene una tale espressione non viene (in generale) compilato e non potrà quindi venir eseguito. Un caso ancora diverso è quello in cui l'espressione da valutare contiene variabili indefinite. In questa situazione la valutazione dell'espressione può venir eseguita senza errori apparenti ed il solo sintomo dell'errore è un valore finale casuale.

Nel seguito, considereremo cosa avviene nel caso di espressioni che mescolano valori e variabili di tipi diversi, ma non incompatibili tra loro, cioè espressioni che il compilatore riesce a tradurre in codice oggetto senza dare errori. Questa situazione è problematica perché le operazioni macchina si applicano su valori dello stesso tipo. Per esempio, i computer possono eseguire l'operazione di somma di 2 operandi interi e anche la somma di 2 operandi reali, ma non la somma tra un intero ed un reale. Quindi cosa fa il compilatore se deve tradurre un'espressione come `2 + 3.14`? Ovviamente ci sono 2 possibilità: o trasformare l'intero 2 in un reale (scrivendo 2 in forma floating point) oppure trasformare il reale 3.14 in un intero, per esempio troncando la parte decimale riducendo 3.14 a 3. Il compilatore C++ sceglie sempre la prima possibilità. Il motivo è semplice e logico: un intero occupa meno byte (4) di un `double` (8 byte) e quindi la conversione dell'intero in `double` non comporta mai una perdita di informazione: ogni intero tra -2^{31} e $2^{31}-1$ ha una rappresentazione precisa in floating point con 8 byte. E' chiaro che invece trasformare 3.14 in un intero ci faccia perdere i decimali .14.

Quindi il compilatore C++ quando compila espressioni con valori di tipi diversi e compatibili, trasforma alcuni di questi valori in modo che ogni operazione si applichi a valori dello stesso tipo e nel farlo segue il seguente semplice principio: **vengono applicate le conversioni che producono il minimo rischio di perdita di informazione**. Le trasformazioni di tipo che soddisfano questo principio, vengono chiamate **promozioni**. In Sezione 9.4 si possono trovare maggiori dettagli sulle promozioni e in generale su tutti i tipi di conversione e su cosa comporti in pratica convertire un valore da un tipo ad un altro tipo.

Espressioni molto usate nei programmi sono le espressioni booleane, cioè quelle il cui valore è di tipo booleano. Queste espressioni generalmente usano gli operatori relazionali come `>` `<` `>=` `<=` `==` (uguale) `!=` (diverso) e gli operatori logici `&&` `||` `!`. Un esempio di espressione booleana è la seguente. Si assuma che `x` sia una variabile di tipo `char`: `(x>='a') && (x<='z')`, ha valore `true` se `x` ha come R-valore un carattere alfabetico (tra 'a' e 'z') ed altrimenti l'espressione ha valore `false`. Si noti che questa espressione usa il fatto che la codifica ASCII dei caratteri assegna ai caratteri alfabetici dei valori interi contigui e coerenti con l'ordine alfabetico. Più precisamente, 'a' ha codice ASCII 97, 'b' 98 e così via. Naturalmente il codice ASCII codifica in modo simile anche i 10 caratteri numerici e le maiuscole.

2.4 A cosa servono i tipi

Capitolo 3

Istruzioni di base

Questo capitolo è dedicato alla descrizione delle istruzioni di base del C e C++. Chiariamo subito che queste istruzioni si trovano in qualsiasi linguaggio di programmazione della grande famiglia dei linguaggi imperativi, come per esempio Fortran, Pascal, ma anche quelli orientati ad oggetti come C++, Java eccetera.

Tratteremo in primo luogo le istruzioni di input e di output e successivamente esamineremo l'assegnazione, il comando condizionale ed il comando iterativo **while**.

In generale un'istruzione ha l'effetto di modificare il valore di qualche variabile. Per evitare di creare malintesi chiariamo subito che una variabile in programmazione ha due valori: l'R- e l'L-valore. L'R-valore è quello che viene informalmente chiamato valore e che (normalmente) è un valore del tipo della variabile in questione. L'R-valore viene però immagazzinato in memoria e l'L-valore di una variabile è l'indirizzo della memoria in cui l'R-valore è immagazzinato.

Nel seguito, per spiegare il significato delle istruzioni, useremo spesso la nozione di **stato del calcolo** che spiega l'R-valore di tutte le variabili in un dato momento. Più formalmente, lo stato del calcolo in un dato momento dell'esecuzione è rappresentato da una funzione **S** tale che ogni variabile attiva **x** del programma, **S(x)** è l'R-valore di **x** in quel momento. Il caso che **x** sia indefinita viene rappresentato con **S(x)=⊥**. Il significato di ogni istruzione può venire specificato attraverso le modifiche che l'istruzione opera sullo stato del calcolo.

3.1 Input/Output

I programmi devono poter scambiare informazioni con l'esterno ed a questo servono le operazioni di lettura e stampa, dette di input/output e abbreviate in i/o.

Ci limiteremo a spiegare le operazioni più semplici che poi useremo sempre nel seguito del testo. Operazioni di i/o maggiormente sofisticate sono descritte in www.cplusplus.com. Un programma comunica con l'esterno per mezzo di dispositivi molto diversi: in un computer moderno, l'input standard è la tastiera, l'output standard è lo schermo, ma un programma potrebbe poter scrivere o leggere da un dispositivo USB o da CD o DVD o semplicemente da un file nella memoria del computer o anche un file che risiede nella memoria di qualche altro computer raggiungibile da quello su cui il programma esegue. Sarebbe troppo complicato se ci fossero istruzioni di i/o distinte per ciascun dispositivo. Quindi tutti questi dispositivi vengono visti dai programmi nello stesso modo: come un **file**. Vediamo

innanzitutto cos'è un file, successivamente ci occuperemo di come un programma acceda a un file e delle principali operazioni di i/o disponibili.

3.1.1 I file

Concettualmente un file è una sequenza di dati che terminano con un carattere particolare, detto **end of file**. Ci sono 2 tipi di file: file di **testo** e file **binari**. Un file di testo è costituito da una sequenza di byte ognuno dei quali rappresenta un carattere, contiene cioè la codifica ASCII estesa di un carattere. Questi file in generale contengono un testo, per esempio un programma o un romanzo. Dato che ciascun carattere è rappresentato dalla sua codifica ASCII estesa, per leggere il testo contenuto in un file di testo, è necessario usare un programma che traduce ciascun byte nel corrispondente carattere scritto sullo schermo. Un esempio di un tale programma è un editore di testo.

I file **binari** sono ancora sequenze di byte (tutto è una sequenza di byte in un computer), ma questi byte non sono codifiche di caratteri, ma sono rappresentazioni interne al computer di valori, per esempio valori interi, reali eccetera. Ovviamente nel computer i valori di tipo carattere sono rappresentati sempre con il codice ASCII esteso e quindi un file di testo e binario che contengono valori di tipo carattere sono (fondamentalmente) uguali. Al contrario, se i valori contenuti in un file binario sono per esempio interi, se si cerca di leggerlo con un editore di testo, si ottiene sullo schermo un testo assolutamente incomprensibile. Nonostante che sequenza di 8 bit possa venire interpretata come il codice di un carattere secondo la codifica ASCII estesa, la sequenza dei caratteri ottenuti traducendo in questo modo un file binario, sarà senza senso.

Facciamo un semplice esempio per chiarire la differenza tra file di testo e file binari. Consideriamo il valore intero 8. In un file di testo il valore 8 viene rappresentato da un solo byte che contiene la codifica ASCII estesa del carattere '8', cioè 56 (per la precisione il valore binario 00111000), mentre in un file binario il valore 8 è rappresentato da 4 byte come ogni valore intero, cf. Tabella 2.1: i primi 3 composti da tutti 0, mentre il quarto conterrebbe: 00001000, cioè la codifica binaria di 8. Il valore -8 verrebbe rappresentato su un file di testo da 2 byte (uno che contiene la codifica ASCII estesa di '-' e l'altro quella di '8'), mentre in un file binario verrebbe rappresentato ancora da 4 byte che rappresentano in binario il valore 4294967288, che è la rappresentazione in complemento a 2 dell'intero -8, cioè $2^{32}-8$.

Comunque ogni file è una sequenza di byte e, generalmente, la lettura di un file inizia sempre dal primo byte e successive letture leggono i byte successivi. Vedremo che è possibile leggere un byte alla volta e anche molti byte alla volta. Comunque, se, dopo alcune letture, si raggiunge l'end of file, significa che il contenuto del file è stato completamente letto. Questo modo di procedere si dice **sequenziale**. Esistono anche altre modalità di lettura non sequenziali (random) di cui non ci occuperemo. L'output inizia generalmente con un file vuoto e ogni operazione di scrittura sul file aggiunge byte in modo sequenziale, cioè successivi valori scritti sul file vengono appesi in coda a quelli scritti precedentemente. In questo testo ci occuperemo solo di file di testo che sono letti e scritti in modo sequenziale. Sono più semplici e sono anche quelli usati più frequentemente.

3.1.2 Collegamento tra programma e file

Il collegamento tra un programma ed un file avviene associando al file un oggetto di tipo **stream**. Trattandosi di oggetti, nel seguito spiegheremo solo come usare gli **stream**, senza entrare nei dettagli. Un oggetto contiene dati e offre funzioni (dette **metodi**) per manipolare questi dati. Nel caso degli **stream** i metodi offerti sono le operazioni di i/o sui file. Per usare un file in un programma si devono inserire alcune istruzioni nel programma:

- i) all'inizio del programma va inserita la direttiva

```
#include<fstream>,
```

- ii) inserendo, per esempio nel main, la dichiarazione,

```
ifstream XX("pippo");
```

si crea lo **stream** **XX** che viene associato al file **pippo**, il quale viene simultaneamente **aperto** per eseguire input, cioè i suoi dati sono ora a disposizione del nostro programma per operazioni sequenziali di lettura;

- iii) per aprire il file **minni** in output, cioè per scriverci sopra, si deve inserire nel programma la dichiarazione: `ofstream YY ("minni");` che apre il file **minni**.

L'apertura di un file può fallire. Per esempio, la dichiarazione del punto (ii) fallirebbe se il file **pippo** aperto in input non fosse presente nella directory corrente. Ci possiamo accorgere del fallimento controllando il valore di **XX** dopo la sua dichiarazione. Infatti, in caso di fallimento, il valore di **XX** è 0. L'operazione di apertura può aprire file che si trovano in cartelle qualsiasi (anche diverse da quella corrente), specificando, tra le doppie di virgolette, il cammino per raggiungere il file dalla directory corrente.

Se il file **le minni** della dichiarazione del punto (iii) non fosse presente nella directory corrente, allora esso verrebbe automaticamente creato. Quindi l'apertura di un file in output difficilmente fallisce. Va tenuto ben presente però che, qualora il file **minni** esistesse già, la sua apertura in output causerebbe la cancellazione del suo contenuto. L'idea è che un file destinato a ricevere output debba essere inizialmente vuoto. Le modalità di apertura dei file che abbiamo appena presentato sono le più semplici ed esse consentono di aprire file (di testo) da usare in modo strettamente sequenziale. Altre modalità si possono trovare consultando le fonti già citate.

Quando un file ha esaurito la sua funzione, esso può venire chiuso. Se **XX** è lo **stream** associato al file da chiudere, allora `XX.close();` chiude il file associato a **XX**. Dal momento in cui questa operazione viene eseguita, **XX** non è più associato ad alcun file, anche se resta una variabile di tipo **fstream** che potrà di nuovo venire associata ad un file (lo stesso di prima o diverso), per esempio con l'istruzione `XX.open("chi_vuoi");`.

Per rendere facili le operazioni di i/o che si riferiscono alla tastiera ed allo schermo, nel namespace **std**, il C++ associa ad essi 2 **stream** che quindi sono a disposizione dei programmatori. Lo **stream** **cin** è associato all'input standard (tastiera), mentre lo **stream** **cout** è associato all'output standard (schermo). Nell'Esempio 1.1, abbiamo usato questi 2 **stream**.

3.1.3 Operazioni di i/o

Gli stream sono degli oggetti e fanno quindi parte della parte orientata agli oggetti del C++. Ci limiteremo quindi ad usarli senza neppure cercare di spiegarli. Comunque una cosa dobbiamo dirla sugli oggetti: gli oggetti sono delle strutture in cui convivono dei dati e delle funzioni per manipolare questi dati. Nel gergo orientato agli oggetti le funzioni vengono chiamate **metodi**. Ovviamente i metodi definiti negli stream di i/o sono principalmente operazioni di i/o. Studieremo solo 2 metodi per l'input e 2 metodi per l'output.

- visto che consideriamo solo file di testo, cioè composti di sequenze di caratteri, è naturale leggere da questi file un carattere alla volta e scrivere su questi file un carattere alla volta. Se `XX` e `YY` sono, rispettivamente lo stream di input e quello di output, allora l'istruzione, `char c=XX.get()`, legge il prossimo carattere (dal file associato a `XX`). Questo carattere diventa l'R valore della variabile `c`. Quindi l'operazione di input cambia lo stato del calcolo per quanto riguarda la variabile letta (`c` nell'esempio). Il file è letto sequenzialmente, quindi la prima `get` legge il primo carattere del file, la seconda `get` legge il secondo carattere e così via. La lettura non cambia il contenuto del file. Quindi ad una successiva apertura si ritroverebbe il contenuto del file intatto. La scrittura di un carattere può venire effettuata con la seguente istruzione: `YY.put(c)`; il valore di `c` (variabile di tipo `char`) viene appeso alla fine del file associato allo stream `YY`.

Vale la pena di osservare bene la sintassi delle 2 operazioni appena viste. Per esempio, in `YY.put(c):YY` è l'oggetto di tipo `stream` e `put` è un metodo di questo oggetto. Il punto in `YY.put(c)`; indica proprio l'appartenenza di `put` allo stream `YY` e si chiama operatore di **appartenenza**. Lo stesso vale per `char c=XX.get()`.

- Generalmente i file di testo contengono sequenze di caratteri che rappresentano valori separati da spazi, per esempio sequenze di interi o di reali e sarebbe molto comodo riuscire a leggere (scrivere) un valore intero o reale con un'unica operazione di lettura (scrittura), senza leggere (scrivere) carattere per carattere. Gli stream di i/o offrono operazioni che consentono questa comodità. Esse sono le operazioni `>>` e `<<` già viste nell'Esempio 1.1. Vediamo meglio come funzionano. Il contenuto di un qualsiasi file di testo è una sequenza di stringhe di caratteri separate da caratteri di separazione (spazio e accapo), dove ogni stringa rappresenta un valore per esempio un numero intero oppure un reale. L'istruzione `XX >> x`; in cui `x` è una variabile intera, causa la lettura da `XX` della prossima stringa di caratteri numerici fino al primo separatore che si incontra. Se, anziché caratteri numerici, su `XX` si trovano altri caratteri, per esempio alfabetici, allora si verifica un errore che spesso causa la non terminazione della lettura. Da questo si può capire immediatamente che la comodità della lettura fatta con `>>`, causa una perdita di robustezza dei programmi, nel senso che si ottengono programmi incapaci di resistere a situazioni impreviste, come trovare caratteri inattesi su `XX`.

C'è un'altra particolarità della `>>` che si deve osservare. Supponiamo che `x` e `y` siano variabili `int`. Se eseguiamo `XX >> x >> y`; quando il file associato a

`XX` contiene 12 34, allora, dopo la lettura, `x` avrà R-valore 12 e `y` 34. Tutto normale? Forse, ma occorre notare che il contenuto del file è in realtà la seguente sequenza di caratteri: `'1' '2' ' ' '3' '4'` e quindi la lettura ha saltato il carattere spazio `' '` il che è coerente col fatto che esso funge da separatore. Insomma con la `>>` non si possono leggere i caratteri di separazione contenuti nel file (spazi e accapo). Quanto appena descritto è vero anche se la lettura concerne una variabile di tipo `char`, come in, `char c; XX >> c;`. Anche in questo caso non vengono letti i caratteri di separazione (spazi e accapo). Un programma che mostra in modo chiaro questo fenomeno e lo contrasta con quello che succede con l'operazione `get`, è discusso negli Esercizi 3.5, 3.6 e 3.7.

Riconsideriamo l'esempio precedente. Se `x` è intera, la lettura, `XX >> x;` trasforma automaticamente i caratteri `'1'` e `'2'`, presenti sul file, nella rappresentazione interna dell'intero 12 (cioè con 4 byte in complemento a 2) e questo diventa l'R-valore di `x`. Questo significa che il tipo della variabile che viene letta (cioè `int` nell'esempio) determina quale sequenza `W` di caratteri ci deve essere sul file di input perché l'operazione di lettura riesca normalmente. La lettura che riesce trasforma `W` nella rappresentazione interna del valore rappresentato da `W`. Quindi se nel file, anziché `'1'` e `'2'` ci fosse `'1'`, `'.'` e `'2'`, allora la lettura avrebbe un comportamento anomalo (provare per credere) perché il tipo `int` non prevede un punto nei suoi valori. Se invece `x` avesse tipo `double` la lettura funzionerebbe normalmente e `x` assumerebbe l'R-valore 1.2 (rappresentato in modo floating point con 8 byte). Nel caso in cui `x` avesse tipo `double` ed il file contenesse `'1' '2' ' ' '3' '4'`, allora verrebbe calcolata la rappresentazione floating point su 8 byte di 12 ed assegnata come R-valore a `x`.

In conclusione, l'operazione di lettura `>>` si *fida* del tipo della variabile letta per sapere quali caratteri aspettarsi sul file (fragilità), e traduce la stringa di caratteri letta nella rappresentazione interna appropriata al tipo della variabile letta (comodità). Quindi l'operazione di lettura `>>` è comoda, ma fragile. Se le aspettative determinate dal tipo della variabile letta non si avverano, la lettura può avere risultati anomali. Da questo segue che ogni applicazione rivolta ad utenti qualsiasi non potrà mai effettuare letture con `>>`. Dovrà sempre leggere l'input come sequenza di caratteri e successivamente verificare che la sequenza letta corrisponda alle attese o no.

Anche l'operazione di output `<<` esegue automaticamente una traduzione, ma in senso inverso rispetto a quella dell'input. Infatti, essa traduce l'R-valore della variabile da stampare (naturalmente si tratta della rappresentazione interna al computer del valore) nella sua rappresentazione esterna, cioè nella sequenza di caratteri che la rappresenta, ed è questa rappresentazione che viene scritta sul file. Ogni nuova operazione di output inserisce un nuovo valore dopo quelli stampati in precedenza senza lasciare spazi o accapo tra un valore ed il successivo. Se non si inseriscono esplicitamente separatori, si rischia di ottenere un file che sarebbe impossibile leggere successivamente.

Esercizio 3.1 *Realizzare un programma che crea un file di testo in output, scrive, (con `>>`), su questo file i valori interi 11, 32, 455 e 6, chiude il file, lo riapre in input e cerca di leggere dal file i 4 valori interi appena scritti. Per finire chiude il file definitivamente. Attenzione a separare i valori quando li scrivete!*

Come spiegato in precedenza, la lettura sequenziale di un file fa in modo che ad ogni operazione di lettura venga letto il prossimo byte (o gruppo di byte). Insomma è come se sul file ci fosse un segno che avanza ad ogni lettura per indicare il prossimo byte che verrà letto. Prima o poi questo segno arriverà alla fine del file, cioè all'end of file, e chiaramente, una volta raggiunto quel punto, successive letture non avrebbero senso. Segnaliamo che tali letture, benché erronee (in generale) non causano l'interruzione dell'esecuzione del programma, ma leggono valori sballati. Lo `stream` associato al file ci offre il metodo `eof()` (`eof` abbrevia end of file) che restituisce il booleano `true` solo quando la fine del file è stata raggiunta. Per un `ifstream XX` si controlla di aver raggiunto la fine del file con la seguente invocazione: `XX.eof();`. Si deve fare attenzione al fatto che le diverse operazioni di lettura introdotte in Sezione 3.1.3 possono presentare un comportamento diverso rispetto al raggiungimento dell'end of file. Questo fenomeno è illustrato nell'Esempio 3.5.

Sull'input/output ci sarebbero molte altre cose da dire. Per esempio gli `stream` di input ci offrono anche altre operazioni di input come la `getline` che legge i prossimi caratteri sullo `stream` fino al primo carattere di accapo. Inoltre ci sono anche operazioni di output formattato, in cui è possibile fissare il numero di spazi disponibili per la stampa di un dato valore. È interessante anche sapere che esiste la possibilità di definire file su cui è possibile sia leggere che scrivere dati e su cui queste operazioni non sono necessariamente sequenziali. Queste cose non ci serviranno nel seguito del libro. I lettori possono trovare informazioni su questi aspetti tecnici dell'input/output su internet, per esempio all'indirizzo: www.cplusplus.com.

3.2 Assegnazione

L'istruzione più semplice, ma comunque più importante, del C++ è l'**assegnazione**. L'assegnazione ha la forma, `x = (2*y) / (3*z);` in cui `x`, `y` e `z` sono variabili. L'esecuzione di una tale assegnazione produce il seguente effetto. Supponiamo che lo stato del calcolo al momento precedente l'esecuzione dell'assegnazione sia `S`, allora viene calcolato il valore `v` di `(2*S(y)) / (3*S(z))` (si ricordi che `S(y)` è l'R-valore di `y` nello stato `S`) e `v` diventa l'R-valore di `x`. Quindi, dopo l'esecuzione di questa assegnazione, il nuovo stato del calcolo sarà `S'` che è uguale a `S` per ogni variabile diversa da `x` e uguale a `y` per `x`. Si osservi che tra le variabili che appaiono nell'espressione a destra dell'uguale di un'assegnazione può esserci anche la variabile che appare alla sinistra dell'uguale. Come per esempio in `x = (2*y) / (3*x);`. L'esecuzione di una tale assegnazione non ha nulla di diverso dalla precedente.

La descrizione di quanto avviene durante l'esecuzione di un'assegnazione spiega (finalmente) i nomi R- e L-valore delle variabili. Infatti abbiamo appena visto che per la valutazione dell'espressione a destra del segno di uguale si usano gli R-valori delle variabili che vi appaiono (e destra è Right in inglese), mentre il valore `v` di questa valutazione viene immagazzinato nella RAM all'indirizzo che è l'L-valore della variabile che appare alla sinistra dell'assegnazione (e sinistra è Left in inglese).

Il C++ consente di scrivere assegnazioni in forme abbreviate come, `potenza*=2;` e `esponente++;`. Esse corrispondono alle seguenti assegnazioni normali: `potenza*=2;` \Rightarrow `potenza = potenza*2;` e `esponente++;` \Rightarrow `esponente = esponente + 1;`

Lo stile abbreviato di queste assegnazioni proviene dal C ed aveva originalmente il duplice scopo di permettere di scrivere codice conciso e anche di ottenere codice

oggetto più efficiente. In realtà i compilatori moderni non hanno bisogno delle forme abbreviate per ottimizzare il codice che producono e quindi la forma abbreviata è ora motivata solo dalla ricerca della concisione del codice e forse dall'abitudine. Nel seguito useremo spesso gli operatori `++` e `--` sia in forma postfissa che prefissa, come per esempio in `esponente++`; e `++esponente`;. Entrambi questi comandi effettuano l'assegnazione `esponente = esponente + 1`; e non c'è alcuna differenza tra i 2 comandi se essi sono usati da soli, mentre c'è differenza se essi vengono usati all'interno di un'espressione più complessa. Consideriamo un semplice esempio: confrontiamo l'effetto di eseguire `int x=1; x=(x++)*2`; con quello di eseguire `int x=1; x=(++x)*2`;. Nel primo caso, dopo l'esecuzione, il valore di `x` è 3, mentre nel secondo caso il valore di `x` diventa 4. Il motivo è che nel primo caso l'incremento richiesto da `x++`, viene eseguito dopo l'assegnazione `x=1*2` e quindi il valore finale di `x` è 3, mentre nel secondo caso l'incremento richiesto da `++x` viene fatto immediatamente e quindi l'assegnazione diventa `x = 2*2`.

3.3 Condizionale

La prossima istruzione da considerare è l'istruzione condizionale. Essa ha la forma, `if (EXP) C1 else C2`; dove `C1` e `C2` sono blocchi di istruzioni e `EXP` è un'espressione booleana, cioè un'espressione il cui valore è di tipo `bool`. In realtà, visto che il C++ *confonde* `bool` con `int` (con 0 equivalente a `false` e tutti gli altri valori interi equivalenti a `true`), `EXP` può avere anche un valore `int`. L'esecuzione di questa istruzione in un certo stato del calcolo **S** ha il seguente effetto: viene calcolato il valore dell'espressione booleana `EXP` nello stato del calcolo **S** e se questo valore è `true` (o un qualsiasi intero diverso da 0), allora viene eseguito il blocco di istruzioni `C1`, altrimenti viene eseguito `C2`. In entrambi i casi, dopo l'esecuzione di `C1` o `C2` il calcolo continua con l'istruzione che segue il condizionale. La Figura 3.1 contiene il diagramma a blocchi del condizionale nella sua forma completa con entrambi i rami `C1`, detto tradizionalmente il ramo `then`, e `C2`, detto il ramo `else` ed anche nella forma con il solo ramo `then`.

3.4 Cicli while

Ogni linguaggio di programmazione che si rispetti deve possedere un'istruzione iterativa che permette di ripetere un certo blocco di istruzioni per tutto il tempo che una data condizione è verificata. Senza una tale istruzione iterativa (o qualcosa di analogo) un linguaggio è incapace di realizzare calcoli realmente interessanti.

L'istruzione iterativa più semplice del C++ è il `while` che ha la seguente forma: `while (EXP) C`;, in cui `EXP` rappresenta un'espressione booleana (o interpretabile come booleana) e `C` è un blocco di istruzioni. `EXP` è detta la **condizione** di permanenza nel ciclo, mentre `C` è il **corpo** del `while`.

L'effetto di eseguire questa istruzione in uno stato del calcolo **S** è come segue: viene calcolato il valore dell'espressione booleana `EXP` nello stato del calcolo **S** e se esso ha valore `true` (o intero diverso da 0) allora viene eseguito il blocco `C`. L'esecuzione del corpo generalmente cambia lo stato da **S** in **S'** ed in questo nuovo stato si torna ad eseguire `while (EXP) C`;. Se in **S'** `EXP` è ancora `true` allora si esegue di nuovo il corpo e così via. Prima o poi (sperabilmente) si raggiunge

uno stato del calcolo S'' tale che in questo stato EXP abbia valore `false` e allora l'esecuzione del `while (EXP) C`; termina ed il calcolo continua dall'istruzione che segue immediatamente il corpo del `false`. Lo stato del calcolo alla fine del ciclo sarà S'' .

Può capitare che EXP non diventi mai `false`. In questo caso (a meno di istruzioni di salto contenute nel corpo) l'esecuzione non esce mai dal `false` e questo fenomeno viene chiamato un **ciclo infinito**. Ovviamente quando questo succede siamo in presenza di un programma errato. Il diagramma a blocchi del `false` è in Figura 3.2. Nella stessa Figura 3.2 viene anche illustrata la variante `do-while` del `while` che esegue il corpo sempre almeno una volta visto che valuta l'espressione EXP solo dopo questa prima esecuzione del corpo.

3.5 Esempi

Illustriamo ora le nuove istruzioni appena introdotte realizzando alcuni semplici programmi. Iniziamo modificando l'Esempio 1.1.

Esercizio Risolto 3.2 *Dopo aver letto 2 valori dallo `stream` di input `cin` ed averli assegnati alle variabili x e y , vogliamo sommare i due valori ed assegnare questo valore ad una nuova variabile intera SOM e per ultimo, usando l'istruzione condizionale, se il valore di SOM è maggiore di 0 vogliamo assegnare il valore di SOM ad y , altrimenti, (cioè se $SOM \leq 0$), vogliamo assegnare SOM a x . Il programma che compie queste azioni segue. Esso ci mostra alcune cose interessanti. Per esempio che le dichiarazioni possono essere in qualsiasi punto di un blocco, cf. la dichiarazione di SOM . Inoltre il programma illustra l'uso del condizionale che ci consente di fare cose diverse a seconda dello stato del calcolo in cui ci troviamo. Per esempio assumiamo che i valori letti per x e y siano 2 e -4. Allora SOM assume il valore $2-4=-2$ e quindi la condizione $SOM>0$ in questo stato del calcolo è falsa e quindi viene eseguito il ramo `else` del condizionale cioè l'assegnazione $x=SOM$. Per cui lo stato finale S è come segue: $S(x)=-2$, $S(y)=-4$ e $S(SOM)=-2$. Se invece di 2 e -4 dallo `stream` di input vengono letti i valori 5 e -4 le cose sarebbero andate diversamente? In che modo?*

```

1  #include<iostream>
2  using namespace std;
3  main() {
4      int x, y;
5      cout << "inserire 2 interi";
6      cin >> x >> y;
7      cout<<"valore di X="<< x <<"valore di y="<< y;
8      int SOM;
9      SOM= x+y;
10     if (SOM > 0)
11         y=SOM;
12     else
13         x=SOM;
14     cout<<"valore di x="<< x <<"valore di y="<< y;
15 }
```

Esercizio Risolto 3.3 *Consideriamo ora di voler leggere degli interi dall'input standard fino a che non si legge il valore 0 e dei valori letti si vuole calcolare quanti sono positivi e quanti negativi (quindi lo 0 non viene contato). Benché l'esercizio*

sia semplice proponiamo due diverse soluzioni, una che usa un ciclo *while* ed una seconda con un *do-while*, vedi Figura 3.2. La prima soluzione è la seguente:

```

1  #include<iostream>
2  using namespace std;
3  main() {
4      int pos=0, neg=0, x; cin>>x;
5      while (x != 0) {
6          if(x < 0)
7              neg=neg+1;
8          else
9              pos=pos+1;
10         cin>>x;
11     }
12     cout<<"neg="<< neg <<" pos="<<pos<<endl;
13 }
```

Un punto da notare è che *neg* e *pos* vanno inizializzati a 0 prima di essere usati, altrimenti otterremmo dei valori casuali o comunque sbagliati. Si noti anche che la prima lettura viene fatta prima di entrare nel ciclo in modo da avere la variabile *x* pronta per il test di permanenza nel ciclo. Le successive letture sono eseguite alla fine del corpo del ciclo cioè immediatamente prima di tornare alla valutazione del test di permanenza. Il fatto che serva una lettura fuori dal ciclo ed una nel ciclo, indica che probabilmente il problema può essere risolto in maniera più naturale con un ciclo *while-do* che permette di fare anche la prima lettura nel corpo del ciclo visto che il test di permanenza è alla fine del ciclo stesso. Questa soluzione alternativa segue.

```

1  #include<iostream>
2  using namespace std;
3  main() {
4      int pos=0, neg=0, x; cin>>x;
5      do {
6          cin>>x;
7          if (x < 0)
8              neg=neg+1;
9          else
10             if(x>0)
11                 pos=pos+1;
12     } while(x!=0);
13     cout<<"neg="<< neg <<" pos="<<pos<<endl;
14 }
```

Come previsto questa soluzione necessita di una sola lettura anziché due come nella soluzione precedente. Però questa semplificazione la si paga con la necessità di un condizionale più complicato nel corpo del ciclo. Infatti, dopo la lettura, *x* potrebbe essere 0 nel qual caso non dobbiamo cambiare né *neg* né *pos* e, per garantire questa condizione, siamo obbligati ad avere il test *x>0* nel ramo *else* in modo da escludere il caso *x=0*. Forse per questo semplice problema si può pensare che sia ovvio che le nostre 2 soluzioni siano giuste, ma in generale non è così e ci sarà bisogno di ragionare per arrivare ad una soddisfacente convinzione della correttezza dei nostri programmi. Nel prossimo Capitolo, questo esempio ci servirà da apripista per mostrare come questi ragionamenti possono venire organizzati.

Esercizio Risolto 3.4 Si vuole realizzare un programma che legge 10 interi dall'input standard, memorizza il minimo e il massimo tra i valori letti e alla fine li stampa sull'output standard. Il programma deve avere un ciclo *while* che esegue 10

volte e che dopo aver letto il prossimo intero lo confronta con il massimo ed il minimo tra i valori letti in precedenza e li modifica a seconda dei casi. Chiamiamo le due variabili i cui R-valori sono, rispettivamente, il massimo ed il minimo tra i valori letti in precedenza, *max* e *min*. Sembra semplice, ma c'è un problema. Alla prima esecuzione del *while*, non abbiamo ancora letto alcun valore e quindi che valore dovranno avere *max* e *min*? Questo problema si presenterà spesso in altri esercizi proposti nel seguito. Lo affronteremo in modo completo subito. Possiamo assegnare a *max* e *min* dei valori ad hoc che fanno funzionare le cose, oppure leggere il primo valore (sappiamo che c'è visto che sono previste 10 letture) e assegnarlo sia a *max* che a *min* e dopo leggere gli altri 9 valori. Pensiamo prima alla soluzione con i valori ad hoc. Per *max* abbiamo bisogno di un valore che sarà certamente minore o uguale di ogni valore intero che potremo leggere. Questo valore è ovviamente *INT_MIN*: il minimo intero rappresentabile. Analogamente, per *min*, il valore giusto è *INT_MAX*. Vediamo un programma che segue questa idea.

```

1  #include<iostream>
2  using namespace std;
3  main() {
4      int x, i=0, max=INT_MIN, min=INT_MAX;
5      while (i<10) {
6          cout << "inserire il prossimo intero";
7          cin >> x;
8          if(x > max)
9              max=x;
10         else
11             if(min>x)
12                 min=x;
13         i=i+1;
14     }
15     cout << "il valore massimo e' " << max << ", il valore minimo e' " << min;
16 }
```

Questo programma non fa quello che vogliamo. Basta infatti considerare il caso in cui i valori letti siano, 1, 2, ..., 10, per vedere che alla fine *max*=10, il che è giusto, ma che *min* sarà rimasto tristemente *INT_MAX*! Certo se i 10 valori non fossero sempre crescenti, allora il programma funzionerebbe, ma non possiamo accontentarci di un programma che è quasi sempre corretto! Possiamo correggerlo? Certamente, ma non è possibile considerare *min* solo quando *max* non cambia. Perché i valori ad hoc con cui li abbiamo inizializzati vanno sempre cambiati, quindi dobbiamo essere sicuri che ciascuna delle due variabili sia confrontata almeno una volta con uno dei valori letti. Un programma che corregge l'errore segue.

```

1  // SOLUZIONE 1
2  #include<iostream>
3  using namespace std;
4  main() {
5      int x, i=0, max=INT_MIN, min=INT_MAX;
6      while(i<10) {
7          cout << "inserire il prossimo intero";
8          cin >> x;
9          if(x > max) {
10             max=x;
11             if (i==0)
12                 min=x;
13         }
14         else
```



```

15     if(min>x) {
16         min=x;
17         if(i==0) //($) questo commento e' usato nel
18             max=x; //($) primo esercizio del prossimo Capitolo
19     }
20     i=i+1;
21 }
22 cout << "il valore massimo e' " << max << ", il valore minimo e' " << min;
23 }

```

È corretto? la risposta è affermativa, ma non è facile convincersene. Nell'Esercizio Risolto 4.2, mostreremo una prova di correttezza per questo programma. Resta la seconda strada per risolvere il nostro problema: leggere il primo valore ed assegnarlo sia a *max* che a *min* e poi leggere gli altri 9 valori.

```

1  // SOLUZIONE 2
2  #include<iostream>
3  using namespace std;
4  main() {
5      int x, i=1, max, min;
6      cout << "Inserire il primo intero";
7      cin >> x;
8      max=min=x;
9      while(i<10) {
10         cout << "Inserire il prossimo intero";
11         cin >> x;
12         if(x>max)
13             max=x;
14         else
15             if(min>x)
16                 min=x;
17         i=i+1;
18     }
19     cout << "il valore massimo e' " << max << ", il valore minimo e' " << min;
20 }

```

Praticamente è la prima soluzione proposta, quella che si è rivelata sbagliata. Siamo sicuri che questa diversa inizializzazione la renda corretta? Non è evidente e solo con la prova di correttezza che verrà sviluppata nel Capitolo 4 potremo esserne sicuri.

Esercizio Risolto 3.5 Questo esercizio ha lo scopo di illustrare e confrontare alcune operazioni di i/o viste nella Sezione 3.1.3. L'Esempio è strettamente collegato ai due esercizi seguenti che andrebbero infatti considerati immediatamente dopo questo. Si tratta di scrivere un programma che apre come input un file di testo *pippo.cpp* e legge il suo contenuto carattere per carattere ricopiando i caratteri letti sul file di output standard (il video, associato allo *stream cout*). La coppia di operazioni di lettura e stampa è ripetuta grazie all'uso del comando iterativo *while* la cui condizione di permanenza è *! PP.eof()*, cioè le due operazioni sono ripetute fino a che l'end of file di *PP* non è raggiunto.

```

1  #include<iostream>
2  using namespace std;
3  main() {
4      ifstream PP("pippo.cpp");
5      if(PP != 0) { //se l'apertura ha avuto successo
6          while(! PP.eof()) {
7              char c;

```

```

8      c = PP.get();
9      cout << c;
10     }
11     PP.close();
12 }
13 else
14     cout << "errore nell'apertura del file" << endl;
15 }

```

Questo programma controlla se l'apertura del file ha avuto successo e nel caso sia fallita, stampa sul video un apposito messaggio d'errore e termina senza fare altro. Solo nel caso l'apertura abbia avuto successo, legge, carattere per carattere, il contenuto del file e stampa sul video ciascun carattere immediatamente dopo averlo letto. Cambiando opportunamente il nome `pippo.cpp` è possibile usare questo programma per copiare a video ogni file (di testo).

Esercizio 3.6 Si chiede di memorizzare il programma descritto nell'Esercizio precedente in un file di nome `pippo.cpp`, di compilarlo e di eseguirlo. L'esecuzione di questo programma farà comparire sul video il testo del programma stesso seguito da un ultimo carattere strano. Questo carattere strano è causato dal fatto che, dopo che viene letto l'ultimo carattere buono del file, `PP.eof()` non diventa immediatamente `true`. È necessaria un'ulteriore operazione `get` per far scattare `PP.eof()` a `true`. Visto che questa lettura non trova nulla da leggere, l'R-valore di `c` diventa il carattere strano che viene stampato per ultimo.

Esercizio 3.7 Si chiede di modificare il programma dell'Esercizio precedente, sostituendo l'operazione di lettura con la seguente: `PP >> c;`. Sia ancora `pippo.cpp` il file che contiene il programma modificato. L'esecuzione di questo nuovo programma stampa sul video tutti i caratteri del file `pippo.cpp` omettendo gli spazi e gli accapo. In sostanza il contenuto del file viene scritto tutto di seguito. Questo strano comportamento è dovuto a quanto detto in precedenza sull'operazione `>>`: essa non legge i caratteri di separazione (spazio e accapo), ma li usa solo per separare le stringhe di caratteri buoni. Invece l'operazione `get` legge tutti i caratteri, anche quelli di separazione. Va notato anche che ora nessun carattere strano conclude la stampa. Il motivo è sempre lo stesso: l'operazione `>>` salta i separatori e quindi, dopo la lettura dell'ultimo carattere buono, salta qualunque carattere di separazione lo segua e attiva subito l'end of file.

3.6 Sulla visibilità delle variabili

È utile capire cosa succede alle variabili ed ai loro valori quando un programma viene eseguito. Abbiamo già visto che il programma sorgente viene tradotto dal compilatore in un equivalente programma oggetto che consiste di istruzioni macchina. Quando il programma oggetto viene eseguito, esso deve risiedere nella memoria RAM del computer ed un'altra area della RAM contiene i valori delle variabili del programma. Eseguire un programma significa che in ogni momento una particolare istruzione del programma oggetto viene eseguita e che un particolare sottoinsieme delle variabili del programma sono **attive**. Quindi la zona di memoria RAM che contiene i valori delle variabili del programma non è statica, ma al contrario essa cambia sia nella sua dimensione sia nei valori che contiene perché in ogni momento

cambia l'insieme delle variabili attive. Cerchiamo di capire quali sono le variabili attive in ogni momento dell'esecuzione e come vengono gestite. In generale, un programma è costituito da blocchi annidati gli uni negli altri, dove ogni blocco può contenere dichiarazioni di variabili (oltre a istruzioni). Ecco un main che consiste di 3 blocchi annidati con dichiarazioni e operazioni di output:

```

1  main()
2  //(*)
3  {
4      int x=0; //...(0)
5      {
6          int y=1; //...(1)
7          {
8              int z=2; //...(2)
9          }
10     cout << x << y << endl; // (1')
11     }
12     cout << x << endl; // (0')
13 }
14 //(*)

```

L'esecuzione inizia al punto (*) e in quel momento nessuna variabile è ancora attiva. Quando l'esecuzione entra nel blocco (0), la variabile **x**, dichiarata in questo blocco, diventa attiva, mentre le variabili **y** e **z** non sono ancora attive. Lo potranno diventare solo quando l'esecuzione entra nel secondo e nel terzo blocco, rispettivamente. Ma cosa significa in pratica che una variabile diventa attiva? Significa che le viene attribuita un'area di memoria RAM in cui verrà custodito il suo R-valore. Questa attribuzione di memoria viene chiamata **allocazione della variabile** e l'indirizzo di memoria attribuito è l'L-valore della variabile. Quindi quando l'esecuzione raggiunge il punto (0), sarà allocata la variabile **x**, quando raggiunge il punto (1), verrà allocata anche **y** e in (2) sarà allocata anche la **z**. È molto importante capire che in (1') l'esecuzione è uscita dal blocco più interno e quindi la variabile **z** non è più attiva e l'area di memoria che le era stata attribuita viene tolta e torna disponibile per l'allocazione di altre variabili. Questa operazione si chiama **deallocazione della variabile**. Quindi in (1') saranno attive solo le variabili **x** e **y** e quindi la stampa avrà successo e farà apparire 0 1 sullo schermo. Il tentativo di stampare **z** in (1') avrebbe causato un errore di compilazione con una spiegazione del tipo: variabile **z** non esiste. A questo punto non sarà una sorpresa il fatto che in (0') anche **y** verrà deallocata e solo **x** resta attiva, mentre in (*) tutte e 3 le variabili saranno deallocate.

Da questa descrizione dovrebbe essere facile vedere che la gestione dei dati manipolati da un programma segue un andamento a pila: quando l'esecuzione entra in un blocco, le variabili dichiarate nel blocco vengono allocate sulla cima della pila e vengono deallocate dalla cima della pila quando l'esecuzione esce dal blocco stesso. La Figura 3.3 illustra questa gestione a pila. Visto che l'allocazione e la deallocazione delle variabili dipende solamente dal blocco in cui le variabili sono dichiarate, esse sono dette **automatiche** per sottolineare la loro differenza con variabili i cui valori sono gestiti in un modo diverso che verrà illustrato in Sezione 11.1. Una variabile automatica è attiva nel periodo che va dalla sua allocazione alla sua deallocazione. La **visibilità** di una variabile è sempre il blocco in cui è dichiarata, dalla sua dichiarazione in poi. Va ricordato che la pila delle variabili attive è realizzata in una parte della memoria RAM.

Nell'esempio di Figura 3.3, per semplicità, abbiamo considerato una sola dichiarazione per blocco. Il caso di più dichiarazioni in un blocco viene gestito in modo analogo: lo spazio necessario per tutte le variabili dichiarate viene allocato sulla pila nel momento in cui l'esecuzione entra nel blocco e quella stessa zona di memoria viene deallocata all'uscita dal blocco. Non dobbiamo dimenticare la relazione che intercorre tra la pila dei dati ed il codice oggetto che sta eseguendo. Supponiamo che nel blocco (2) ci sia un comando che usi la variabile `x`, allora la variabile usata è quella allocata in fondo alla pila in Figura 3.3(2). D'altra parte, se all'interno del blocco (2) ci fosse una nuova dichiarazione di `x`, per esempio `double x`; che precede l'istruzione che usa `x`, allora l'istruzione farebbe riferimento a questa nuova `x` che sarebbe allocata in cima alla pila, come mostra la Figura 3.4(a). Nella Figura 3.4(a) si deve anche osservare che entrambe le variabili `x` sono allocate, ma quella in cima alla pila oscura l'altra visto che si trova più vicina alla cima della pila (si ricordi che la pila cresce verso il basso). Quando l'esecuzione esce dal blocco (2), la pila diventerà quella di Figura 3.4(b) e quindi l'output in (1') stamperà l'R-valore della `x` che sarà tornata visibile visto che non ci sono più altre `x` sopra di lei nella pila.

Una variabile attiva ha un L-valore ed un R-valore. L'L-valore è l'indirizzo di memoria RAM (sulla pila dei dati) in cui l'R-valore viene immagazzinato. Ricordiamo che la lettera R sta per Right (destro) e la L per Left (sinistro). La spiegazione di questi nomi è stata data in Sezione 3.2.

Esiste un'importante differenza tra l'R- e l'L-valore di una variabile attiva. Mentre l'R-valore di una variabile viene "deciso" dalle istruzioni che definiscono la variabile e quindi in generale cambia durante l'esecuzione del programma, il suo L-valore viene deciso dal programma che gestisce la pila dei dati e quindi non può venire deciso né modificato dal programma in esecuzione. In compenso il programma può conoscere ed usare l'L-valore delle sue variabili. Una variabile viene detta **indefinita** quando essa è attiva, ma non è inizializzata. Essendo attiva, memoria è stata allocata nella pila dei dati per contenere il suo R-valore, ma i byte a disposizione contengono una sequenza di bit casuale, cioè quello che casualmente è contenuto in quel momento in quei byte della RAM. Fare uso dell'R-valore di una variabile indefinita è un errore che può anche essere insidioso da scoprire. Infatti, ogni tipo di valore all'interno di un computer è rappresentato come una sequenza di bit, quindi una sequenza casuale di bit viene sempre interpretata come un R-valore coerente con il tipo della variabile, causando, senza alcuna segnalazione d'errore, il calcolo di valori erranei.

Il corpo di un `while` o il ramo `then` o `else` di un condizionale costituiscono un blocco e naturalmente questi blocchi al loro interno ne possono contenere altri con livello di annidamento arbitrario. Inoltre ogni blocco può contenere dichiarazioni. Ogni dichiarazione appartiene ad un solo blocco e bisogna essere precisi nel definire quale sia. Il blocco di appartenenza di una dichiarazione D è il blocco che contiene D ed è tale che non ci sia alcun altro blocco, annidato in esso, che contenga D (attenzione: proprio D, non un'altra dichiarazione uguale a D). Quindi, delle dichiarazioni che appartengono ad un blocco, non fanno parte quelle che compaiono nei blocchi annidati.

La visibilità o usabilità di una variabile inizia dal punto del programma immediatamente successivo alla sua dichiarazione e si estende fino alla fine del blocco cui la dichiarazione appartiene. Eventuali blocchi annidati sono inclusi nella visibilità. Quindi le variabili dichiarate in un certo blocco sono, in linea di principio, visibili anche nei blocchi annidati.

Il C++ (così come ogni linguaggio di programmazione con tipi) fissa una regola molto semplice per le dichiarazioni di variabili, la **Regola della dichiarazione singola** che è la seguente: **in uno stesso blocco non ci può essere, più di una dichiarazione di una variabile**. In uno stesso blocco non sono ammesse neppure dichiarazioni di una variabile con tipi diversi. Il motivo è facile da capire: se ci fossero 2 dichiarazioni diverse di uno stesso nome in uno stesso blocco, ci sarebbero 2 variabili con lo stesso nome contemporaneamente attive nel blocco e quindi, qualora questo nome venisse usato, sarebbe impossibile sapere a quale delle due variabili si intende fare riferimento. D'altra parte in un programma è consentito definire diverse volte variabili con lo stesso nome purché queste dichiarazioni appartengano a blocchi diversi, anche annidati. Nel caso di ridefinizioni in blocchi annidati, la ridefinizione di una variabile in un blocco annidato produce l'oscuramento della variabile con lo stesso nome dichiarata nel blocco esterno. Questo è necessario per avere sempre una sola variabile con un dato nome visibile. Questo fenomeno di oscuramento è stato già descritto in Figura 3.4 che mostra come il meccanismo dell'oscuramento viene facilmente realizzato tramite la gestione dei dati automatici con una pila. Altre informazioni sulla visibilità delle variabili si trovano nelle Sezioni 5.3, 7.4 e 9.7.

Concludiamo la Sezione con un'osservazione importante sulle dichiarazioni che si trovano nel blocco costituito dal corpo di un comando iterativo. Ad ogni iterazione, l'esecuzione entra nel blocco, producendo l'allocazione delle variabili dichiarate al suo interno, giunge alla fine del blocco, producendo la deallocazione delle stesse variabili e così via per ogni iterazione. Quindi il risultato del seguente programma è la stampa di 1 0 per 1 0 volte: ad ogni iterazione si alloca una nuova `x` con R-valore 1 0 e la successiva somma non si trasmette da un'iterazione all'altra.

```
1  int i=0;
2  while(i<10) {
3      int x=10;
4      cout << x << endl;
5      x = x+10;
6      i++;
7  }
```


Capitolo 4

La correttezza dei programmi

4.1 Regola di prova del *while*

4.2 Altri esempi di prove di correttezza

4.2.1 Esempio di gestione delle eccezioni

Capitolo 5

Puntatori, array ed aritmetica dei puntatori

I puntatori sono una nozione fondamentale per il C. Nel C++ essi sono affiancati dai riferimenti. In questo capitolo illustreremo entrambe le nozioni sottolineando la stretta relazione esistente tra di esse e spiegando il motivo per cui i riferimenti hanno soppiantato i puntatori nei linguaggi più moderni come Java. Successivamente introdurremo gli array assieme al costrutto iterativo FOR che si usa spesso per percorrere gli array. Cura particolare sarà dedicata a spiegare il tipo degli array a più dimensioni. Aver chiarito questo argomento tornerà molto utile per capire *l'aritmetica dei puntatori* che è descritta nella sezione finale del capitolo.

5.1 Puntatori e riferimenti

5.2 Array e for

5.3 Il tipo degli array

5.4 L'aritmetica dei puntatori

5.5 Stringhe alla C e array di caratteri

Capitolo 6

?

Capitolo 7

Funzioni

7.1 Funzioni

7.2 Passaggio dei parametri

7.3 Funzioni ed arrays

7.4 Variabili globali

7.5 Funzioni e valori restituiti

7.6 Esercizi commentati sulle funzioni

7.7 Esercizi proposti

Capitolo 8

Gestione dinamica dei dati e liste

Le variabili viste finora sono dette automatiche perchè la memoria RAM per contenere il loro R-valore viene allocata e deallocata automaticamente secondo la disciplina a pila descritta nella sezione 3.6. Ci sono casi in cui esrvono dati la cui vita e le cui dimensioni possono venire gestiti a seconda del bisogno ed al di fuori delle regole automatiche. L'abilità di creare e distruggere tali dati si dice **gestione dinamica dei dati** ed i dati prodotti in questo modo sono detti **dinamici**. Utilizzando la gestione dinamica dei dati costruiremo strutture dati ricorsive come le **liste concatenate** e gli **alberi binari** sulle quali vedremo moltissimi esempi di funzioni ricorsive. La gestione dinamica dei dati viene realizzata con alcune semplici istruzioni C++ che verranno introdotte nella prossima sezione. Inoltre, visto che i dati dinamici non seguono le regole di gestione dei dati automatici, essi non possono venire allocati nella pila dei dati automatici, ma vengono invece allocati in un ' area di memoria RAM diversa della pila che si chiama **heap**.

8.1 Gestione dinamica dei dati

Le istruzioni del C++ per la gestione dinamica dei dati sono le seguenti. L'operazione di allocazione della memoria è la funzione **new** T, in cui T è un tipo qualsiasi. Una tale invocazione richiede al sistema operativo di allocare una zona di memoria RAM sufficiente a contenere un valore di tipo T. In caso la richiesta venga soddisfatta, la memoria viene allocata in una parte della RAM chiamata **heap** ed essa resta a disposizione del programma finchè il programma stesso non la dealloca eseguendo il comando di deallocazione **delete**. Lo heap è un'area di memoria RAM diversa da quella che contiene la pila in cui vengono gestite le variabili automatiche. La funzione **new** ha il seguente prototipo: **T* new(T);**. L'invocazione di **new**, se ha successo, riserva sullo heap una sequenza di byte della dimensione giusta a contenere un valore di tipo T e restituisce l'indirizzo del primo byte di questa sequenza. Se invece l'allocazione non ha successo, il valore restituito è 0. In programmi in cui la robustezza è importante conviene, dopo ogni invocazione di **new**, testare se il valore ritornato è 0 oppure no. Una **new** può fallire perchè la sua richiesta di memoria supera la disponibilità di memoria del PC al momento della richiesta; è raro che un tale fallimento avvenga per programmi come quelli che svilupperemo in questo corso. Vediamo un esempio di allocazione dinamica.

```
1      struct S{int x,y; char a,b};
```

```
2     main(){
3         S* p = new S[10];
4         if(p==0) throw(..errore..) //errore d'allocazione, gestiscilo
5         p[0].x = 10;
6         p[2].a = 'h';
7     }
```

In questo frammento di programma allochiamo un array di 10 strutture S. L'array viene acceduto attraverso il puntatore p a cui possiamo applicare l'operatore di subscripting